2024년 2학기

뇌-마음-행동 개별연구 보고서

이름	이홍균
학과	심리학과
학번	2020-16993
지도교수	데이터사이언스 대학원 오민환 교수님
연구 제목	Elementary Sequential Decision Making Under Uncertainty: Focusing on Case Studies in Neuroscience Research

1. 연구의 배경 및 중요성

일반적으로 학습자는 학습 결과에 대한 피드백에서 과제 수행의 향상에 도움이 되는 정보를 추려내고 이를 학습 활동에 반영하고자 한다 (Pekrun et al., 2013). 이처럼 상호작용으로부터 배운다는 것은 학습과 지능에 관한 거의 모든 이론의 기저에 깔린 개념이다. 이는 뇌 과학 연구에서도 보편적으로 받아들여진 사실이다. 뇌는 상호작용하는 여러 뇌 영역으로 이루어진 네트워크로 뇌 과학 연구의 시초인 David Ferrier 는 'The Functions of the Brain'에서 뇌를 '복잡한 전체 (complex whole)'로 정의하였다 (Stam C., 2024).

뇌 과학 연구의 방향

강화학습: 뇌와 상호작용 학습의 공통점

강화학습은 주어진 상황에서 행동의 결과가 최대의 보상을 갖도록 행동을 학습한다. 이때 학습자는 어떤 행동을 선택할지에 대한 기준을 제공받지 않는다. 오로지 시행착오(trial-and-error)를 통해 최대의 보상을 주는 행동을 탐색해야 한다. 또한, 각 상황 속에서의 행동 선택은 그 행동에 직접적으로 영향을 받는 보상만이 아니라, 그 다음에 이어지는 상황에도 영향을 미친다. 즉, 강화학습은 한번의 학습 상황이 아닌 연속적인 학습 상황을 전제하며 각 상황에서의 보상과 더불어 연속적인 보상에 영향을 미치는 지연된 보상까지 고려하게 된다. 시행착오와 지연된 보상은 강화학습과 다른 기계학습들과 구별되는 가장 큰 특징에 해당된다.

또한 강화학습은 탐험(exploitation)과 활용(exploration) 사이를 절충하는 과정에 해당된다. 많은 보상을 얻기 위해서 강화학습 학습자는 과거에 보상을 획득하는데 효과적이었던 검증된 행동들을 '활용'하고 싶어한다. 하지만 반드시 과거의 행동들이 최대의 보상이라는 보증이 없다. 때로는 과거에 해보지 않았던 행동을 '탐험'해보기도 해야 한다. 즉, 학습자는 최대의 보상을 얻기 위해 이미 경험한 행동들을 '활용'하거나 더 좋은 행동을 선택하기 위해서 '탐험'을 수행해야 하는 선택의 상황에 놓이게 된다. 둘 중 하나만 선택해서는 최대의 보상을 이룰 수 없기에 활용과 탐험 사이에서 적절한 선택을 하게 된다. 이는 비지도학습은 활용에만 치중되었다는 점에서 차이가 있다.

뇌 과학 연구와 강화학습의 통합

이처럼 강화학습은 시행착오를 통한 학습, 지연된 보상의 고려, 탐험과 활용 간의 균형이라는 특징을 통해 다른 기계학습 방법론들과 차별화된다. 이러한 특징들은 특히 뇌의 학습 과정과 밀접한 연관성을 가진다. 뇌는 끊임없는 상호작용 속에서 환경에 적응하고, 선택과 피드백을 기반으로 미래 행동을 조율하며 학습을 진행한다. 따라서 강화학습은 뇌 과학 연구의 특성과 본질적으로 잘 부합하며, 이를 활용한 연구는 기존의 방법론으로는 포착하기 어려운 뇌의 복잡한 학습 메커니즘과 상호작용 과정을 이해하는 데 있어 강력한 도구가 될 수 있다. 실제로 강화학습은 심리학 및 신경과학 분야와 상호작용하며 두 분야의 발전에 큰 도움이 되었으며 기계학습의 모든 형태 중 사람이나 동물의 학습과 가장 유사한 것이 강화 학습니다.

본 연구는 강화학습 중 다중선택 문제와 그것의 표준적인 해결 방법에 대한 배경 정보를 다룬다. 그리고 강화학습이라는 방법론이 뇌 과학 연구에서 기존 접근법과 어떤 차이를 만들어내는지, 그로 인한 새로운 통찰이나 발전 가능성을 제공하는지에 초점을 맞춘다. 특히, 동일한 연구 주제를 다루더라도 강화학습의 적용 여부와 그 방식에 따라 어떤 결과의 차이가 나타나는지 비교·분석함으로써, 강화학습이 뇌 과학 연구에서 가지는 독창성과 잠재적 효과를 구체적으로 밝히고자 한다. 이러한 비교 연구는 강화학습을 뇌 과학 연구에 더욱 정교하게 통합할 수 있는 가능성을 열어줄 뿐만 아니라, 인공지능과 신경과학의 융합 연구를 더욱 발전시키는 기틀을 마련할 것으로 기대한다.

2. 연구 방법 및 결과

강화학습의 네가지 구성 요소

강화학습을 구성하는 구성요소에는 학습자와 주변 환경을 제외하고 네 가지가 있다. 우선, 첫번째는 정책(policy)으로 특정 시점에 학습자가 취하는 행동을 정의하는 규칙을 의미한다. 구체적으로 알고리즘은 학습자가 인지한 주변 환경의 상태에 대해 학습자가 취해야 할 행동을 알려주는 것으로 알고리즘 그 자체 만으로도 학습자의 행동을 결정할 수 있다. 일반적으로 알고리즘은 확률론적으로 행동을 선택하게 되며 모든 정책의 목표는 행동의 탐색(exploration)과

활용(exploitation)을 균형 있게 수행하는 것이다. 정책은 지도학습의 지침 (instruction)과 혼동될 수가 있다. 정책은 학습자가 현재상태(state)에서 어떤 행동을 해야 하는지를 정의한 규칙 또는 함수라면 지침은 학습에 대한 정답을 제공한다. 두번째 구성 요소는 보상 신호(reward signal)이다. 일반적으로 강화학습에서 학습자의 유일한 목표는 장기간에 걸쳐 학습자가 획득하게 되는 보상의 총합을 최대화하는 것이다. 이를 위해 매시간마다 주변 환경은 학습자에게 보상이라는 신호를 전달하는데 학습자는 보상신호의 크기로부터 자신의 행동이 좋고 나쁨을 판단한다. 만약 보상 신호가 작았다면 학습자는 추후에 유사한 상황에 대하여 다른 선택을 하도록 정책을 바꿀 수 있다. 세번째 구성 요소는 가치 함수(value function)이다. 보상 신호가 단기간에 선택의 불호에 대한 정보를 제공한다면 가치 함수는 장기적인 관점에서 선택의 좋고 나쁨에 대한 정보를 준다. 가치는 선택을 처음 시작한 순간부터 일정 시간동안 학습자가 기대할 수 있는 보상의 총량이다. 따라서 비록 순간의 선택에 대한 보상이 적더라도 장기적인 관점에서 추후에 얻게 될 보상이 크다면 현재 순간의 선택은 가치가 높은 선택인 것이다.

마지막 구성 요소는 모델(model)이다. 강화학습의 최종 목적은 보상의 극대화인 만큼 네가지 구성요소 중 보상이 주목적이고 가치는 실현되지 않은 보상의 기대값에 대한 예측인 만큼 부수적인 것이다. 하지만 선택을 할 때 당장의 보상을 보고 선택하는 것이 아닌 가치를 고려한다. 즉, 행동의 선택은 보상의 최대화가 아닌 가치의 최대화가 되도록 하는 것을 판단을 기준으로 한다. 하지만 가치를 예측하는 것은 어렵기에 정확한 가치를 예측하는 것이 강화학습의 핵심 문제점이다. 그리고 그 문제를 해결하는 방안 중 하나가 모델 기반(model-based) 방법이다. 모델은 학습자가 놓인 환경을 구조화한 것으로 환경이 어떻게 변화할 지를 추정하도록 해준다. 이런 추정을 바탕으로 미래의 상황을 실제로 경험하기 전에 가능선만을 고려하여 행동을 결정하는 계획(planning)을 수행하게 된다. 모델 기반 방법은 모델과 계획을 활용하여 강화 학습의 방법을 해결하는 방법이다.

연구 방법: 강화학습 모델과 알고리즘

강화학습의 구성요소들은 상호작용하며 학습자의 행동 선택 과정을 결정한다. 이 중에서도 모델은 강화학습의 문제 해결 방식에서 중요한 역할을 한다. 특히, 정책과 가치 함수를 최적화하는 과정에서 모델은 환경의 구조와 보상 시스템을 예측하여 학습자가 직접 경험하기 어려운 상황에서도 학습을 가능하게 한다. 뇌 과학 연구처럼 단순한 보상 신호나 가치 함수만으로는 복잡한 환경에서 장기적인 행동 계획을 세우는 데 한계가 있을 때에 모델 기반 방법은 인간의 뇌를 이해하는데 필수적인 도구이다. 본 연구에서는 2 개 모델(Multi-Armed Bandit; MAB, Contextual Bandit)을 중심으로 연구문제를 정의하고 이를 해결하는 3 가지 알고리즘(ε-greedy, Upper Confidence Bound; UCB, Thompson Sampling; TS)으로 분석하고자 한다.

많은 모델 중에서 위의 두 가지를 선택한 이유는 본 연구에서 강화학습 문제를 가장 간단한 형태의 MAB 모델에서 시작하여, 문맥 정보를 포함하는 Contextual Bandit 모델로 확장하기 위해서이다. 간단한 모델에서 시작하면, 각 알고리즘이 기본적인 학습 원리와 행동 선택에 미치는 영향을 명확히 관찰할 수 있으며 모델과 알고리즘의 신뢰성을 단계적으로 검증할 수 있다. 단순성에서 복잡성으로의 확장은 과학적 탐구의 기본적인 접근법에 해당이 되고 뇌 또한 단순한 행동 선택에서 시작해 점차 복잡한 의사결정 및 환경 적응 학습으로 발전한다는 점에서 유사하다. 위와 같은 단계적 접근 방식을 통해서 뇌의 학습 메커니즘 전반을 보다 포괄적으로 탐구할 수 있을 것이다.

모델 Model

(1) 다중선택 Multi-Armed Bandit (MAB)

다중선택 모델은 Robbins(1952)에 의해서 처음 소개되었다. MAB 는 Sutton 과 Barto(2018)가 제시한 강화 학습의 가장 단순한 형태이다. 각 시간 t 에서 학습자는 K 개의 가능한 행동 중 하나인 a_t를 선택하고, 이에 대한 보상 r_{at}를 받는다고 가정한다. r_{at}는 각 정책에 따라 시간 단계에서 학습자가 받는 보상이다. 각 행동에 대한 보상은 사전에 알려져 있지 않으며, 보상은 특정 확률 분포에 의해 결정된다. 이는 에이전트가 보상 r_a를 정확하게 추정하거나 예측할 수 있을 만큼 충분한 지식을 얻기 위해 하나의 행동 a를 여러 번 수행해야 함을

의미한다(Sutton and Barto, 2018). 즉, MAB 문제에서의 목표는 학습자가 행동을 선택하는 데 사용하는 정책(ϕ)을 설계하여, 아래와 같이 총 보상 $G_{\phi}(T)$를 최대화하는 것이다

$$G_{\phi}(T) = E\left[\sum_{t=1}^{T} r_{at}\right]$$

이 정책은 학습자가 이전 행동들로부터 수집한 지식을 기반으로 한다. 시간 지평선 T 는 학습자의 예산(budget)을 나타내며, 실제로는 항상 유한하다. 그러나 이론적으로 MAB 문제를 분석할 때는 유한 시간 지평선과 T→∞ 로 가는 무한 시간 지평선에 대한 결과가 존재한다(Burtini et al., 2015; Lattimore and Szepesvári, 2020a). 또한 초기 MAB 모델에서 보상은 확률 θ_a 로 성공을 나타내는 1 과 실패를 나타내는 0을 가진 이진 분포로 주로 정의(Robbins, 1952)되며, 베타 분포(Faisal et al., 2020)에 의해서 설명되었다. 서로 다른 행동은 서로 다른 베타 분포를 갖는다(Scott, 2010).

MAB 모델에서 보상의 분포에 대한 또 다른 일반적인 가정은 정규분포를 갖는다는 것이다(Faisal et al., 2020). 이 경우 보상은 0 또는 1 에 국한되지 않고 임의의 값을 가질 수 있게 된다. 각 행동의 보상은 알려지지 않은 평균과 표준 편차를 가지며, 보상을 받을 때마다 학습자는 추정값을 갱신한다(Sutton and Barto, 2018). 베타분포와 정규분포 이외에도 MAB 모델에서 보상의 분포는 다양한 분포를 가정할 수가 있다.

(2) 맥락적 다중선택 Contextual Bandit (CMAB)

MAB 문제는 여러 가지 방식으로 변형될 수 있다. 다만, MAB 는 비연관적인 선택만을 고려한다. 이는 서로 다른 행동을 서로 다른 상황에 연관시킬 필요 없이 학습자는 하나의 가장 좋은 행동을 찾으면 되었다. 즉, 보상의 분포가 하나로 고정되어 있음을 의미한다. 그러나 일반적인 강화학습 문제에서는 하나의 상황만 있는 것이 아니다. 특정 상황에서의 행동의 가치가 가장 높은 선택이 다른 상황에서는 다른 행동의 가치가 가장 높을 수가 있다. 즉, 보상의 분포가 맥락 정보에 따라서 달라질 수 있다. 이처럼 MAB 모델의 문제에 상황의 맥락까지 고려하는 것을 맥락적 다중선택이라고 한다. 시행착오 학습으로 최고의 행동을 탐색하는 동시에 이 행동이 최고가 되는 맥락(상황)까지 행동과 연관시킨 모델이다.

알고리즘 Algorithm

알고리즘을 평가하는 보편적인 기준은 손실(regret)이다. 손실이란 최적 행동에 대한 총 보상과 정책을 사용하는 학습자가 얻은 보상의 차이이다. 손실을 수식화하면 아래와 같다. r^* 는 최적 행동에 대한 기대 보상(즉, 가능한 최고 보상)이다. 손실에 대한 이론적 상한선은 특정 정책을 사용했을 때의 최악의 경우 기대 손실을 나타낸다. 손실 경계가 로그의 형태일 때 해당 정책을 사용해 최적 행동을 발견할 수가 있다(Burtini et al., 2015).

$$R_{\phi}(T) = Tr^* - G_{\phi}(T)$$

(1) 입실론 탐욕적 방법 ε-greedy

$$a_t \doteq \boldsymbol{argmax_a} Q_t(a)$$

학습자는 각 행동에 대해 한 번씩 행동을 수행하여 초기 보상 추정값을 얻는다. 행동의 가치를 추정할 때에 각 시간단계마다 추정 가치가 최대인 행동을 탐욕적(greedy) 행동이라고 한다. 탐욕적 방법에서 학습자는 항상 가장 높은 추정 보상을 가진 행동을 선택한다. 탐욕적 행동을 선택하는 것은 행동의 가치에 현재까지 갖고 있는 지식을 활용하는 것이며 탐욕적 행동이 다른 행동을 선택하는 것은 비탐욕적 행동의 추정 가치를 상승시킬 수 있으므로 탐험하는 것이다. 따라서 탐욕적 방법에서는 초기 단계 이후에는 탐색을 하지 않고 오로지 활용만 한다. 만약 학습자의 초기 보상 추정값이 부정확하다면, 정책은 항상 비최적 행동을 선택하게 되는 문제가 발생한다.

앞선 문제를 해결하기 위해서 입실론 탐욕적 방법은 대부분의 행동 시간 간격동안 탐욕적 선택을 수행하고 상대적 빈도수 ε 을 작은 값으로 유지하면서 탐욕적 선택 대신 모든 행동을 대상으로 무작위 선택을 하는 방법을 사용한다 (Sutton and Barto, 2018). 모든 행동이 선택될 확률은 균등하며, 행동 선택은 행동 가치 추정과 무관하게 이뤄진다. 해당 알고리즘의 장점은 이후 단계의 수가 무한으로 커지면 모든 행동이 선택되는 회수가 무한이 되어 시간 단계 t 에서 추정한 특정한 행동의 실제 가치가 전체 행동을 임의로 선택한다고 했을 때의 추정된 가치로 수렴한다. 실제 행동 가치가 임의 가정시의 행동가치 기대값에 수렴하는 경우 행동의 가치를 더 정확하게 추정할 수 있다. 따라서 최적의 행동을

선택할 확률이 1 - ε 보다 크기에 100%의 확률로 수렴한다. 즉, 입실론 탐욕적 방법은 하나의 좁은 시간 구역을 무작위로 선택하는 방법이다.

(2) 신뢰 상한 행동 선택 Upper Confidence Bound (UCB)

$$a_t \doteq argmax_a \left[Q_t(a) + c\sqrt{\frac{ln\, t}{N_t(a)}} \right]$$

신뢰 상한 행동 선택은 입실론 탐욕적 행동 선택이 비탐욕적 행동을 시도하도록 강제하지만, 탐욕적 행동에 가까운 행동 또는 불확실한 행동 중 어느 쪽도 선호하지 않고 차별 없이 행동을 선택한다는 문제점을 보완한 방법이다. 그 해결방법으로 학습자는 추정된 보상에 추가적인 마진(margin)을 더하여 행동을 평가한다. 이 추가 마진은 보상의 추정값에 대한 불확실성(uncertainty)을 기반으로 계산되며, 이는 지금까지 수행된 총 행동 횟수와 해당 행동이 수행된 횟수에 따라 결정한다. 더 좋은 것은 행동 가치의 추정값이 최대치에 얼마나 가까운지, 그리고 추정의 불확실성이 얼마인지를 고려하여 최적 행동이 될 잠재력에 따라 비탐욕적 행동 중에서 선택하는 방법을 사용한다. 그 결과 UCB 는 모든 행동이 선택되지만 더 작은 가치 추정값을 갖는 행동이나 이미 자주 선택된 행동은 시간에 따라 빈도수가 적어지도록 한다. 즉, UCB 는 행동을 선택할 때 결정론적 방법을 취하지만, 각 단계에서 얻은 표본의 수가 더 적은 행동을 더 선호하도록 탐험이 작동한다 Auer et al. (2002).

(3) 톰슨 표본추출 Thompson Sampling (TS)

톰슨 표본추출은 1933 년 Thompson 에 의해 처음 제안된 알고리즘이다. 이 알고리즘의 핵심 아이디어는 행동을 선택할 확률을 해당 행동이 최적 행동일 확률에 맞추는 것이다. 그래서 베이지안 접근 방식을 기반으로 한 확률적 알고리즘이다.

탐험과 활용 사이의 균형을 효과적으로 조율하기 위해, 현재까지의 관찰 데이터로부터 행동별 성공 확률에 대한 사후 확률을 계산하고 그에 따라 행동을 선택한다. 베이지안 환경에서는 모든 가능한 행동에 대해 즉각적으로 주어질 수 있는 보상의 확률과 그에 따른 행동 가치에 대한 사후 분포를 갱신할 수 있다. 즉, 다음 행동 및 보상을 선택하기 전 그 이전 단계들을 모두 고려하여 그 중에서 가장 좋은 선택을 고를 수 있는 방법이다(Russo et al., 2018).

강화학습 모델과 알고리즘을 활용한 뇌 과학 연구 사례

강화학습 모델(MAB, Contextual Bandit, RL)과 알고리즘(ε-greedy, UCB, TS)은 뇌 과학 연구에서 학습과 행동 선택, 보상 기반 의사결정 과정의 신경적 메커니즘을 설명하는 데 활용되어 왔다. 예를 들어, Multi-Armed Bandit 모델은 단순한 보상 학습 상황에서 도파민 시스템과 행동 선택 간의 연관성을 탐구하는 데 사용되었으며, ε-greedy 알고리즘은 학습 초기 탐험적 행동의 역할을 분석하는 데 중요한 도구로 활용되었다. 맥락적 다중선택모델은 문맥 정보를 고려한 학습 과정에서 신경 활동의 변화와 환경 적응 과정을 설명하는 데 기여하였으며, 이와 관련하여 UCB 와 Thompson Sampling 알고리즘은 인간 뇌가 불확실성을 다루는 방식을 모델링하는 데 유용하게 사용되었다. 마지막으로, RL 모델은 순차적 의사결정과 장기적 보상 학습을 분석하는 데 중요한 역할을 하며, 이는 특히 전두엽과 도파민 시스템의 기능적 역할을 탐구하는 연구들에서 활용되었다.

이와 같은 연구들은 강화학습 모델과 알고리즘이 뇌 과학 연구에서 단순한 행동 선택 문제부터 복잡한 순차적 의사결정 과정까지 다양한 학습 메커니즘을 설명하는 데 강력한 도구임을 보여준다. 이러한 연구 사례들을 각각의 모델과 알고리즘에 따라 정리하고, 기존의 뇌 과학 방법론과 비교 분석함으로써 강화학습이 뇌 과학 연구에 제공하는 통찰을 논의할 것이다.

(1) MAB 연구 사례: 뇌-컴퓨터 인터페이스 개발 신뢰 상한 행동 선택 알고리즘 활용

Fruitet et al. (2012)은 사용자가 운동 심상(Moter Imagery, MI) 움직임을 통해 버튼을 누를 수 있는 버튼형 뇌-컴퓨터 인터페이스 (Brain-Computer Interfaces, BCIs)를 개발하였다. 서로 다른 MI 작업은 사용자마다 최적화된 작업이 다를 수 있으며, 같은 사용자라도 시간마다 달라질 수 있다. Fruitet et al.은 기존 운동 심상 연구에서 주로 사용하던 방법론인 모든 MI 작업에 대해 데이터를 수집하는 균등 보정(uniform calibration)대신, MAB 모델을 활용한 강화학습을 적용하였다. MAB 문제 상황에서 Fruitet et al.의 목표는 최적의 MI 작업의

분류 정확도를 최대화하는 것이었다. 그들은 UCB 알고리즘에 기반한 알고리즘을 개발하였으며 그 결과 기존에 사용하던 균등 보정 방법보다 더 높은 분류 정확도를 제공했다고 보고하였다. 후속 연구(Fruitet et al., 2013)에서 그들의 알고리즘을 온라인 환경에서 테스트한 결과 앞선 실험 상황과 동일한 결과를 보였다.

톰슨 표본추출 알고리즘 활용

P300 타자기는 사용자의 뇌파를 이용하여 특정 글자를 선택할 수 있도록 돕는 BCI 이다. P300 타자기는 글자들이 격자 형태로 배열된 인터페이스에 사용자가 선택하고자 하는 목표 글자가 있는 경우, 해당 글자가 포함된 행이나 열이 강조되었을 때 P300 신호가 뇌에서 발생한다. 해당 신호를 통해서 사용자의 목표 글자를 찾아낸다. 기존의 연구들에서 사용한 방법은 모든 행과 열을 강조함으로써 목표 글자를 고르는데 시간이 오래 걸렸다. 그 이유는 사용자가 신호를 보내는 타겟 글자가 포함되지 않은 행/열에 대한 강조가 계속 발생하는 비효율에 기인한다. 이에 Ma et al.은 TS 알고리즘을 적용하여 P300 타자기의 효율성을 높였다. 이들은 각 행동에 대한 보상 확률을 샘플링하여 보상 확률이 높은 행동을 선택하였다. 선택된 행동이 타겟 글자를 포함했는지 여부를 P300 신호의 발생 여부로 판단하여 보상을 업데이트 하였다. 그 결과, MAB 를 적용한 P300 타자기는 목표가 아닌 행/열에 대한 강조를 줄였고, 목표 글자를 찾는 데 걸리는 시간을 단축하여 성능 개선을 이루었다.

(2) CMAB 연구 사례: Human Behavior

입실론 탐욕적 방법 **활용**

Daw et al. (2006)은 인간의 탐색-활용 딜레마를 해결하는 신경 기제를 분석하기 위해 CMAB 과제에 ε-greedy 를 활용 하였다. 실험 결과, 피험자들은 주로 활용 행동을 선택했으나, 일정한 확률로 탐색 행동을 시도한 것이 관찰되었다. 이러한 행동 데이터를 바탕으로, 탐색 및 활용 행동에 연관된 뇌 활성 패턴을 조사하였다. 기능적 자기공명영상(fMRI) 데이터를 활용한 분석 결과, 활용 행동은 선조체와 배내측 전전두피질의 활성화와 강하게 연관되어 있었으며, 이는 기존 연구에서 보상 기반 학습에 관여한다고 알려진 영역들과 일치하였다. 반면, 탐색 행동은 우측 전두극 피질과 양측 전두간구에서 선택적 활성화가 관찰되었다. 특히, 전두극 피질은 높은 수준의 인지적 제어를 담당하는 영역으로, 탐색 행동이 활용적 경향을 억제하고 새로운 전략을 시도하는 데 중요한 역할을 한다는 점을 알 수 있었다. 이 연구는 탐색과 활용 행동이 신경학적으로 분리된 기제를 통해 조절된다는 점을 제안하며, 탐색 행동이 단순한 보상 기반 학습이 아닌 고차원적 인지적 조절 과정을 필요로 한다는 것을 보여주었다. 후속연구로 이러한 탐색 행동이 전두엽 병리와 같은 행동 장애와도 연관될 수 있다는 내용을 보였다.

3. 연구의 의미

강화학습 모델과 알고리즘은 기존 뇌 과학 연구에서 주로 사용되었던 실험적 접근법이나 통계적 모델과는 본질적으로 다른 점을 가진다. 전통적인 연구 방법론은 특정 변수나 제한된 상황 내에서 학습 과정을 설명하는 데 중점을 두는 반면, 강화학습은 연속적이고 동적인 학습 환경에서의 행동과 보상의 관계를 모사하며, 이러한 관계가 시간에 따라 어떻게 변화하는지를 정량적으로 분석할 수 있었다.

강화학습의 뇌 과학적 확장 가능성

강화학습 모델과 알고리즘의 신경과학적 응용은 단순한 이론적 모델링을 넘어, 실질적인 치료 및 응용 가능성을 가진다. 예를 들어, 탐색과 활용 행동의 신경적 기제를 이해함으로써 전두엽 병리와 같은 인지적 장애를 치료하거나, 강화학습 기반 알고리즘을 활용해 보다 효율적인 뇌-컴퓨터 인터페이스 시스템을 설계할 수 있는 가능성이 제시된다. 나아가, 장기적 보상을 고려하는 강화학습의 특성은 인간의 복잡한 의사결정 및 순차적 학습 과정을 이해하는 데 있어 매우 유용한 도구가 될 것이다.

결론 및 미래 방향

본 연구는 강화학습이 뇌 과학 연구에 제공하는 이론적, 실질적 기여를 분석하고, 이를 통해 인간의 학습 및 행동 선택 과정을 더욱 정교하게 설명할 수 있는 가능성을 탐구하였다. 강화학습과 뇌 과학의 통합 연구는 신경과학적 이해를 심화시킬 뿐만 아니라, 인공지능과 뇌 과학의 융합적 발전을 위한 새로운 연구 패러다임을 제시할 것이다.